

Improving the definition of markers for the watershed transform by combining h-maxima transform and convex-hull

Welton Felipe Gonçalves, Rodrigo Júnior Rodrigues, João Fernando Mari

Instituto de Ciências Exatas e Tecnológicas

Universidade Federal de Viçosa - UFV

Caixa Postal 22 - 38.810-000 - Rio Paranaíba - MG - Brasil

Email: {welton.goncalves, rodrigo.rodrigues, joaof.mari}@ufv.br

Resumo—In this paper we describe a new method to filter regional maxima in the context of applying Watershed Transform with Markers to segment clustered cell in microscopy images. Our approach searches for the best value of h for the H-maxima Transform, in the sense to filter out undesired regional maxima in the Distance Transform. When submitted to the Watershed Transform, these undesired regional maxima lead to a super-segmented image. The criteria considered to infer the best value of h was the solidity, i.e., the ratio between the object area and its convex area, of the segmented objects. The proposed method tests values for h in an interactive way searching to maximize the objects solidity. We compare our approach with other segmentation strategies using a public available dataset with ground-truth images. The proposed method, despite being simple to be implemented, have presented improvements in relation to other watershed segmentation strategies.

Keywords—cell segmentation, watershed transform, h-maxima transform, convex-hull

I. INTRODUÇÃO

A segmentação de células, núcleos e organelas celulares é uma etapa fundamental em diversas aplicações relacionadas à análise de imagens biomédicas, como: contagem, classificação e análise quantitativa [1]. O processo de segmentação de imagens consiste na subdivisão da imagem em suas partes e objetos constituintes para posterior análise. A segmentação é uma das tarefas mais difíceis em processamento de imagens podendo determinar o sucesso ou o fracasso da análise [2]. Existem vários métodos de segmentação de imagens incluindo: métodos baseados em limiarização global [2], limiarização adaptativa [3], algoritmos de agrupamentos [4]–[5], detecção de bordas [2], contornos ativos [6], cortes em grafos [7], Transformada Watershed [8], entre outras.

As aplicações práticas da segmentação de células, núcleos e organelas celulares são inúmeras, dentre as quais pode-se citar: (a) segmentação de neurônios em imagens de microscopia para estudos eletrofisiológicos [9]–[10]; (b) segmentação de leucócitos para análise morfológica e auxílio no diagnóstico de leucemias agudas [11]; (c) segmentação de eritrócitos para análise e auxílio na detecção de anemias como, por exemplo, a falciforme [12]; (d) segmentação de cromossomos em imagens de microscopia para análise de cariótipo [13]; entre diversas outras.

Em muitos casos a análise dessas imagens é realizado

manualmente por profissionais especializados. O problema da identificação manual é que os resultados podem ser imprecisos devido à subjetividade do processo. O processo de análise manual torna-se impeditivo quando o número de imagens e de células é muito grande, o que torna a tarefa desgastante, tediosa e suscetível a erros.

Os métodos pesquisados e apresentados neste artigo estão relacionados com a separação de agrupamentos de células, ou seja, grupos de células localizados muito próximas ou em contato umas com as outras. O problema da segmentação desses agrupamentos de células ou núcleos celulares é uma das principais dificuldades para segmentar imagem de células, culturas de células, núcleos e organelas celulares.

Neste trabalho, é apresentado um novo método que permite melhorar a segmentação de agrupamentos de células utilizando a Transformada Watershed com marcadores. O método proposto consiste em identificar o melhor valor para o parâmetro h da Transformada H-Máxima. Os marcadores são gerados a partir da Transformada da Distância e a transformada H-máxima filtra os máximos regionais menores do que um determinado valor h . Para determinar este valor, adotou-se um critério de qualidade da segmentação baseado na solidez dos objetos, ou seja, na razão entre a sua área e a sua área convexa. O método proposto, basicamente, escolhe o valor de h que maximiza a solidez do conjunto de objetos segmentados pela Transformada Watershed.

Este trabalho está organizado da seguinte maneira: o tema, objetivos, justificativa e contribuições são descritos nesta seção (Seção I). Na Seção II são apresentados os trabalhos relacionados. Na Seção III é descrito o método proposto e o protocolo de validação. Os resultados são apresentados e discutidos na Seção IV e a conclusão e trabalhos futuros estão na Seção V.

II. TRABALHOS RELACIONADOS

Irshad et al. [14] realizam uma revisão do estado-da-arte dos trabalhos envolvendo processamento de imagens aplicado à detecção de patologias em imagens de tecidos celulares obtidas por microscopia. Os autores descrevem alguns dos principais algoritmos utilizados na segmentação de imagens como a limiarização, algoritmos morfológicos, Transformada Watershed, Crescimento de Regiões, dentre outros. Também são realizadas comparações entre os algoritmos para demonstrar os casos em que cada um pode ser particularmente útil.

Cheng e Rajapakse [15] também propuseram uma versão adaptativa da Transformada H-máxima para filtragem de mínimos regionais para aplicação da Transformada Watershed. Os autores utilizam a Transformada H-mínima em detrimento da H-máxima pois ela atua sobre o mapa de distâncias invertido. No presente trabalho, escolheu-se trabalhar com a Transformada H-máxima aplicada diretamente sobre o mapa de distâncias gerado para Transformada da Distância. A Transformada H-mínima Adaptativa proposta por Cheng e Rajapakse depende da escolha de um parâmetro Δ para filtrar adequadamente mínimos regionais indesejados, já o método proposto neste artigo não insere mais nenhum parâmetro para a escolha do h , sendo completamente automatizado de acordo com a razão entre a área dos objetos e a área do seu fecho convexo.

Jung e Kim [16] também tentam estimar o melhor valor de h para a Transformada H-mínima, para isso eles ajustam uma elipse ao contorno dos objetos segmentados e medem a distorção entre a elipse e o contorno. O presente trabalho difere deste por apresentar um critério muito mais simples para avaliar a qualidade da segmentação dado o valor de h , ao invés de quantificar a área residual entre o objeto segmentado e a elipse ajustada, utilizou-se apenas o valor da solidez do objeto segmentado.

Jung et al. [17] também utilizam a Transformada da Distância da imagem segmentada para identificar agrupamentos de células, porém ao invés de definir marcadores para a Transformada Watershed, os autores modelam a uma mistura de Gaussianas a partir do mapa de distâncias utilizando maximização de expectativas paramétrica. Ou seja, eles modelam a separação de grupos de células como um problema de análise de agrupamentos.

III. MATERIAL E MÉTODOS

O método proposto para a segmentação das imagens de células é descrito nas seções seguintes. Primeiramente, é realizada a segmentação inicial das imagens, separando os pixels que representam os objetos dos pixels de fundo das imagens (Seção III-A). Após a segmentação inicial, cada imagem foi recortada de maneira que cada sub-imagem contivesse um único objeto segmentado. Uma vez que este objeto pode ser composto por um grupo de células agrupadas, o método proposto (descrito na Seção III-E) é aplicado a fim de separá-las adequadamente.

A. Segmentação das imagens

Inicialmente, as imagens são pré-processadas usando um filtro Gaussiano com $\sigma = 5,0$ a fim de reduzir o ruído, inerente ao processo de aquisição das imagens [18].

A imagem pré-processada é então segmentada utilizando a limiarização global de Otsu. O algoritmo de Otsu define um valor de limiar que maximiza de maneira ótima a variância entre as classes, que separa os pixels da imagem em pixels de fundo e pixels de objetos, resultando em uma imagem binária [19][20].

Métodos de segmentação por limiarização, como o método de Otsu, não consideram a relação espacial entre os pixels e fazem com que os algoritmos sejam fortemente afetados pelo

ruído. Esse problema é amenizado por meio da aplicação de filtros espaciais na etapa de pré-processamento e, principalmente, por meio de operações de morfologia matemática. A operação de abertura por área é capaz de eliminar objetos com área inferior a um limiar predefinido, que neste trabalho foi empiricamente definido como 300. A operação de reconstrução morfológica é aplicada para preencher eventuais buracos presentes no interior dos objetos.

B. Transformada Watershed

A segmentação pelo método de Otsu em conjunto com a filtragem morfológica é capaz de separar os pixels de objetos dos pixels de fundo na imagem. Entretanto, esse tipo de abordagem não é suficiente para segmentar corretamente agrupamentos de células [19]. A Transformada Watershed é uma técnica eficiente e muito utilizada para separar esse tipo de estrutura [21]. A Transformada Watershed [8], [22] considera a imagem de entrada como uma superfície topográfica e simula a inundação dessa superfície a partir de cada um dos seus mínimos regionais. Barragens são construídas para impedir que as águas provenientes de mínimos regionais distintos se encontrem. As superfícies dos lagos formadas pelas barragens representam as regiões segmentadas na imagem. O processo de inundação termina quando toda a superfície topográfica estiver submersa, e apenas as superfícies dos lagos e as linhas das barragens estiverem visíveis.

Quando aplicada diretamente sobre o gradiente da imagem, a Transformada Watershed resulta, geralmente, em uma imagem supersegmentada devido ao número excessivo de mínimos regionais presentes no gradiente da imagem [23]. As abordagens para solucionar o problema da supersegmentação são organizadas em três categorias: (a) filtragem dos mínimos regionais no gradiente da imagem [24]; (b) definição de marcadores para os objetos para imposição de mínimos regionais [25], [26], [16]; (c) identificação e fusão dos objetos supersegmentados [23], [27].

O uso de marcadores para os mínimos regionais é uma técnica efetiva para reduzir o problema da supersegmentação da transformada watershed [24]. Marcadores são definidos para cada um dos objetos da imagem. O processo de inundação partirá apenas desses marcadores. Definir marcadores únicos para todos os objetos em uma imagem é uma tarefa difícil [23]. Se algum objeto não receber um marcador ele pode ser inundado pela água proveniente de uma região adjacente e gerar um erro de subsegmentação, ou ainda ser inundado pelo lago que representa o fundo da imagem e o objeto não ser identificado. Caso algum objeto receba mais de um marcador ele será supersegmentado e se alguma marcação for definida fora do interior de algum objeto, será criado um artefato [2].

C. Transformada da Distância

A Transformada da Distância [28] é uma ferramenta útil para determinar bons marcadores para a Transformada Watershed. A Transformada da Distância de uma imagem binária I gera uma imagem em níveis de cinza, DT , em que, o valor de todos os pixels $p \in I$ é definido de acordo com a menor distância entre p e o fundo da imagem, $F(I)$ conforme a Equação 1.

$$DT(p) = \min_{q \in F(I)} \|p - q\|, \quad (1)$$

A imagem gerada, DT , corresponde a um mapa de distâncias, em que os pixels de fundo possuem valor 0, e a intensidade dos pixels de objeto aumenta conforme estes se afastam da borda e se aproximam dos centros dos objetos. A distância entre os pixels pode ser computada considerando diferentes métricas, neste trabalho utilizou-se a distância Euclidiana.

D. Transformada H-máxima

Ao aplicar a Transformada da Distância sobre os objetos de uma imagem binária, observa-se que componentes conectados formados por agrupamentos de células resultam em múltiplos picos na imagem transformada. Os máximos regionais (componentes cercados por pixels com intensidade menor) do mapa de distância são bons marcadores para as células. Uma imagem contendo apenas os máximos regionais de uma imagem I , $RMAX(I)$, pode ser obtida a partir da Equação 2,

$$RMAX(I) = I - HMAX_h(I), \quad (2)$$

em que $HMAX_h$ é a Transformada H-Máxima. Devido principalmente às irregularidades nas bordas dos objetos, ainda pode ser possível observar um número excessivo de máximos regionais, o que pode gerar artefatos e erros de supersegmentação. A Transformada H-Máxima, $HMAX_h$, remove máximos regionais com altura menor ou igual a h , e decremente a altura dos demais em h . $HMAX_h$ pode ser calculada reconstruindo a imagem I após subtrair h dela mesma, conforme a Equação 3,

$$HMAX(I) = I \Delta (I - h), \quad (3)$$

em que Δ é o operador de reconstrução morfológica. Dessa forma, a Transformada H-Máxima filtra os máximos regionais deixando apenas os mais relevantes para serem utilizados como marcadores de células. A escolha do valor para o parâmetro h é extremamente importante para o resultado da segmentação, valores muito baixos de h podem aumentar a quantidade de falso-positivos (artefatos e erros de supersegmentação), enquanto valores muito altos podem elevar o número de falso-negativos (células não identificadas e erros de subsegmentações).

E. Usando o Fecho Convexo para definir o valor de h

O método proposto neste artigo consiste em uma abordagem iterativa para a escolha do melhor valor de h para a Transformada H-máxima, de acordo com um critério de qualidade de segmentação baseado no fecho convexo dos objetos segmentados. O critério escolhido foi a razão entre a área de um objeto, $Area$, e a sua área convexa, $AreaConvexa$, também conhecida como solidez (Equação 4):

$$Solidez = Area / AreaConvexa, \quad (4)$$

A solidez permite estabelecer um critério simples e efetivo para inferir a qualidade da segmentação de um agrupamento

de células. O valor da solidez pode variar entre 0 e 1. Valores de solidez próximos de zero indicam que o objeto é composto por um agrupamento de células, devido às concavidades decorrentes das regiões de contato entre elas. Ou seja, quanto maior o número de concavidades no objeto, maior é a probabilidade deste objeto ser um aglomerado de células e mais próximo de 0 será o valor da sua solidez. Já os valores de solidez mais próximos de 1 indicam que existem poucas concavidades e, portanto, que se trata de uma célula individual.

O método proposto deve ser aplicado sobre cada objeto presente na imagem binária após a segmentação inicial (descrita na Seção III-A). Por isso, cada objeto presente na imagem segmentada é recortado e processado individualmente. Inicialmente, cada imagem recortada possui apenas um objeto, que pode ser um grupo de células subsegmentadas. Computa-se, então, a solidez deste objeto, que será utilizada para mensurar a qualidade da segmentação.

A seguir é apresentado o pseudocódigo do método proposto para o cálculo do valor de h em cada recorte da imagem binária contendo um único objeto:

```

01 - PARA cada recorte FAÇA:
02 -    $h \leftarrow 0$ ;
03 -    $MELHOR\_SOLIDEZ \leftarrow 0$ ;
04 -    $MELHOR\_h \leftarrow h$ ;
05 -   FAÇA:
06 -     Computar a Transformada da Distância;
07 -     Computar a Transformada H-Máxima;
08 -     Computar os Máximos Regionais;
09 -     Aplicar a Transformada Watershed (TW);
10 -      $NUM\_OBJS \leftarrow$  Núm. de objetos gerados pela TW;
11 -      $SOLIDEZ \leftarrow 0$ ;
12 -     PARA cada Objeto da Transf. Watershed FAÇA:
13 -        $SOLIDEZ \leftarrow SOLIDEZ + Solidez(Objeto)$ ;
14 -     FIM-PARA;
15 -      $SOLIDEZ \leftarrow SOLIDEZ / Num. de fragmentos$ ;
16 -     SE  $SOLIDEZ > MAIOR\_SOLIDEZ$ :
17 -        $MAIOR\_SOLIDEZ \leftarrow SOLIDEZ$ ;
18 -        $MELHOR\_h \leftarrow h$ ;
19 -     FIM-SE;
20 -      $h \leftarrow h + 1$ ;
21 -   ENQUANTO  $NUM\_OBJS > 1$ ;
22 -   RETORNE  $MELHOR\_h$ ;
23 - FIM-PARA;

```

F. Validação

Após definir diferentes métodos para a segmentação das células é necessário comparar quantitativamente esses métodos. Para isso foram computados os índices de soma normalizada de distâncias (NSD - *normalised sum of distances* em inglês) definida na Equação 5,

$$NSD(I, R) = \frac{\sum_i [I_i \neq R_i] * D(i)}{\sum_i D(i)} \quad (5)$$

em que $D(i)$ é a distância entre o pixel i e a borda do objeto de referência. O valor 0 indica uma segmentação perfeita enquanto 1 indica que não existe sobreposição entre a célula segmentada e a célula de referência.

A distância de Hausdorff representa a maior distância mínima entre a borda dos objetos da imagem segmentada, I , e da imagem de referência, R , conforme a Equação 6.

$$\text{Hausdorff}(I, R) = \max D(i) : S_i \neq R_i \quad (6)$$

O resultado com valor 0 indica a perfeita associação entre os objetos das imagens, porém, o índice não possui limite superior [1].

Os erros de segmentação também foram contados, sendo eles: erros de divisão (ou **supersegmentação**), em que uma única célula foi dividida pelo método; (b) erros de fusão (ou de **subsegmentação**), em que duas ou mais células foram fundidas em uma única; (c) erro de **adição**, em que uma célula foi identificada onde não existia; (d) erro de **remoção**, em que uma célula deixou de ser identificada. Os códigos para a realização da validação foram obtidos juntamente com o conjunto de imagens descrito na Seção IV-A [1].

IV. RESULTADOS


Nesta seção são apresentados os resultados dos experimentos realizados utilizando um conjunto de imagens de células disponível publicamente e com *ground-truth* para a validação e avaliação do método proposto e dos métodos que serão comparados.

A. Conjunto de Dados


Para a realização dos experimentos foram utilizados dois conjuntos de imagens desenvolvidos e disponibilizados por Coelho et al. [1]¹. O primeiro conjunto de imagens é composto por 50 imagens de células U2OS e foi denominado como conjunto U2OS, o segundo conjunto é composto por 50 imagens de células NIH3T3 e foi denominado NIH3T3. Duas imagens do conjunto U2OS e uma do conjunto NIH3T3 não foram consideradas para os experimentos pois não apresentam nenhuma célula em foco. Todas as células localizadas nas imagens foram delineadas manualmente pelos próprios autores, possibilitando a utilização das mesmas como *ground-truth* para a validação de algoritmos de segmentação de células. A Figura 1 mostra uma imagem do conjunto de dados e a sua versão delineada.

O método proposto foi aplicado sobre os dois conjuntos de imagens descritos no parágrafo anterior, o U2OS e o NIH3T3. Outros métodos de segmentação também foram avaliados, sendo eles: a) segmentação por limiarização global de Otsu; b) segmentação por limiarização global de Otsu seguido de filtragem morfológica (Seção III-A); c) Transformada Watershed com os marcadores definidos nos Máximos Regionais da Transformada da Distância; d) Transformada Watershed após filtrar os máximos Regionais da Transformada da Distância com a Transformada H-máxima tradicional considerando $h = 5$. A Tabela I mostra os resultados das distâncias de Hausdorff para todas as imagens para o conjunto H2.

Por meio dos resultados apresentados na Tabela I é possível verificar o impacto das diferentes estratégias de segmentação. A etapa de filtragem morfológica aplicada sobre a imagem



(a)



(b)

Figura 1: Uma das imagens utilizadas nos experimentos. (a) Imagem original. (b) Imagem de referência delineada.

binária resultante da segmentação por limiarização de Otsu resultou em valores melhores para a distância de Hausdorff, entretanto não diminuiu o número de erros de subsegmentação.

A Transformada Watershed com marcadores extraídos diretamente dos Máximos Regionais da Transformada da Distância geraram resultados piores devido ao número excessivo de máximos regionais, gerando, dessa forma, uma imagem supersegmentada. A Transformada Watershed com marcadores definidos após a filtragem do mapa de distâncias pela Transformada H-Máxima com o valor de h fixado em 5 resulta em uma segmentação de melhor qualidade, consegue separar grande parte dos agrupamentos de células existentes nas imagens segmentadas pelo método de Otsu com filtragem morfológica, e não gera supersegmentação excessiva. O método proposto obteve resultados muito próximos ao da Transformada H-Máxima com $h = 5$, isso se deve ao fato de ambos os métodos acertarem na subdivisão de grande parte dos objetos subsegmentados.

A maior vantagem do método proposto em relação ao método com h fixo, é a qualidade das segmentações individuais, como pode ser observado nas Figuras 2 e 3. Nessas figuras são mostrados os resultados da segmentação de grupos de células pelos cinco métodos testados: (a) Otsu; (b) Otsu seguido de filtragem morfológica; (c) Transformada Watershed

¹Disponível em: http://murphyllab.web.cmu.edu/data/2009_ISBI_Nuclei.html

Tabela I: Médias dos índices de validação obtidos após processar todas as imagens de cada conjunto com os métodos descritos. O primeiro valor corresponde ao conjunto U2OS e o segundo ao conjunto H1H3T3.

Método	Otsu	Otsu + Filtragem Morfológica	Transformada Watershed Máximos Regionais	Transformada Watershed - H-máxima ($h = 5$)	Transformada Watershed H-Máxima Variável (nosso método)
NSD	0,20 / 0,37	0,16 / 0,32	0,79 / 0,76	0,14 / 0,32	0,19 / 0,34
Hausddorf	19,02 / 23,44	17,68 / 22,14	43,27 / 33,41	14,12 / 20,68	16,53 / 20,82
Supersegmentação	2,38 / 1,80	2,06 / 1,02	25,63 / 16,55	2,54 / 1,14	3,85 / 2,08
Subsegmentação	3,06 / 2,41	3,08 / 2,43	0,77 / 0,73	1,15 / 1,80	1,06 / 1,45
Adição	3,69 / 3,63	2,33 / 2,47	7,48 / 12,94	2,63 / 3,10	2,90 / 3,63
Remoção	2,00 / 24,12	2,21 / 24,12	3,60 / 27,14	2,25 / 24,12	2,42 / 24,29

sobre os Máximos Regionais da Transformada da Distância; (d) Transformada H-Máxima com $h = 5$ após Transformada da Distância e (e) Transformada H-Máxima com h definido pelo método proposto. Na Figura 2, o método proposto chegou ao valor $h = 32$ e é possível observar que, apesar do número de objetos resultante ser o mesmo, a linha separando as duas células está mais próxima do real limite entre elas. Nessa mesma imagem é possível observar a subsegmentação do método de Otsu e a supersegmentação na Transformada Watershed sobre a Transformada da Distância sem filtragem dos Máximos Regionais. Na Figura 3 o método proposto encontrou um número mais adequado de objetos com o valor de $h = 2$ do que com o valor fixo de $h = 5$.




Figura 2: Resultado dos métodos de segmentação para um objeto: (a) Objeto supersegmentado pela método de Otsu; (b) Imagem supersegmentada pela Transformada da Watershed usando os máximos regionais da Transformada da Distância; (c) Imagem segmentada corretamente filtrando os máximos regionais com a Transformada H-Máxima com $h = 5$; (d) Imagem segmentada corretamente usando o método proposto, que encontrou o valor $h = 32$ gerando uma linha de separação mais exata entre as células.

V. CONCLUSÃO

Este trabalho apresentou um novo método para escolha do valor de h para a Transformada H-máxima. A transformada H-máxima é utilizada para filtrar os máximos regionais na Transformada da Distância de um objeto em uma imagem binária. Os máximos regionais são utilizados como marcadores




Figura 3: Resultado dos métodos de segmentação para um objeto: (a) Objeto supersegmentado pela método de Otsu; (b) Imagem supersegmentada pela Transformada da Watershed usando os máximos regionais da Transformada da Distância; (c) Imagem não segmentada corretamente mesmo filtrando os máximos regionais com a Transformada H-Máxima com $h = 5$; (d) Imagem segmentada corretamente usando o método proposto, que encontra o valor $h = 2$.

para a aplicação da Transformada Watershed com o objetivo de segmentar agrupamentos de células em imagens de microscopia.

O método proposto neste artigo difere dos demais métodos para filtragem de máximos regionais pois: (a) computa um valor diferente de h para cada objeto na imagem binária; (b) estabelece um critério simples e efetivo baseado na solidez dos objetos segmentados pela Transformada Watershed para inferir o melhor valor de h para a Transformada H-máxima.

Uma das principais contribuições deste novo método é a definição de um critério objetivo para a escolha do valor do h . É importante observar que nos experimentos envolvendo a filtragem dos máximos regionais com a Transformada H-máxima convencional, o valor de h foi definido empiricamente, sendo necessário passar pela etapa de validação para se conhecer o melhor valor. No método proposto o melhor valor de h é definido baseado apenas na imagem a ser processada, o que traz uma enorme vantagem, já que na grande maioria das aplicações reais que envolvem segmentação de células, um conjunto de imagens com *ground-truth* não está disponível.

Quando comparado com outros métodos de segmentação de células, o método proposto se mostrou mais eficiente do que os métodos de segmentação baseados apenas nas intensidades dos pixels das imagens como o algoritmo de Otsu. Quando comparado com o método que utiliza a Transformada H-Máxima original, o método apresenta melhora sutil nos índices de validação, porém quando observa-se a qualidade das segmentações visualmente, nota-se que a linha criada para dividir as células está mais bem posicionada, algo semelhante com o que acontece com o método proposto por [15].

Os trabalhos futuros incluem: a) refinar o método proposto, principalmente para lidar com células e objetos com baixa circularidade; b) testar o método proposto em outros conjuntos de imagens; c) testar outros critérios, além do fecho-convexo, para determinar o melhor valor de h ; d) Investigar outros índices de validação de segmentação.

AGRADECIMENTOS

Os autores agradecem aos pesquisadores L. P. Coelho, A. Shariff e R. F. Murphy por disponibilizarem o conjunto de dados e os códigos para validação utilizados nos experimentos. Os autores são gratos ao Instituto de Ciências Exatas e Tecnológicas da UFV - campus Rio Paranaíba e ao Prof. Lucas M. Guimarães pelo apoio financeiro. O autor Welton Felipe Gonçalves é bolsista do programa PIBIC/CNPQ. Agradecemos também à Capes e à FAPEMIG.

REFERÊNCIAS

- [1] Luís Pedro Coelho, Aabid Shariff, and Robert F Murphy. Nuclear segmentation in microscope cell images: a hand-segmented dataset and comparison of algorithms. In *Biomedical Imaging: From Nano to Macro, 2009. ISBI'09. IEEE International Symposium on*, pages 518–521. IEEE, 2009.
- [2] Rafael C Gonzalez and Richard E Woods. *Digital Image Processing (3rd Edition)*. 2007.
- [3] Yousef Al-Kofahi, Wiem Lassoued, William Lee, and Badrinath Roysam. Improved automatic detection and segmentation of cell nuclei in histopathology images. *IEEE Transactions on Biomedical Engineering*, 57(4):841–852, 2010.
- [4] Zhang Yang, Fu-Lai Chung, and Wang Shitong. Robust fuzzy clustering-based image segmentation. *Applied Soft Computing*, 9(1):80–84, 2009.
- [5] Kuo-Lung Wu and Miin-Shen Yang. Alternative c-means clustering algorithms. *Pattern recognition*, 35(10):2267–2278, 2002.
- [6] Sahirzeeshan Ali and Anant Madabhushi. An integrated region-, boundary-, shape-based active contour for multiple object overlap resolution in histological imagery. *IEEE transactions on medical imaging*, 31(7):1448–1460, 2012.
- [7] J SHI. Normalized cuts and image segmentation, iee conference on computation: Vision and pattern recognition, san juan, puerto rico. *Vision Science*, 1997.
- [8] Luc Vincent and Pierre Soille. Watersheds in digital spaces: an efficient algorithm based on immersion simulations. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, (6):583–598, 1991.
- [9] João Fernando Mari, José Hiroki Saito, Amanda Ferreira Neves, Celina Monteiro da Cruz Lotufo, João-Batista Destro-Filho, and Maria do Carmo Nicoletti. Quantitative Analysis of Rat Dorsal Root Ganglion Neurons Cultured on Microelectrode Arrays Based on Fluorescence Microscopy Image Processing. *International Journal of Neural Systems*, 25(8):1550033, sep 2015.
- [10] José Hiroki Saito, João Fernando Mari, Emerson Carlos Pedrino, João Batista Destro-Filho, and Maria do Carmo Nicoletti. Simulated Activation Patterns of Biological Neurons Cultured onto a Multi-Electrode Array Based on a Modified Izhikevich's Model. *Fundamenta Informaticae*, 124:111 – 132, 2013.
- [11] Fabio Scotti. Robust segmentation and measurements techniques of white cells in blood microscope images. In *Instrumentation and Measurement Technology Conference, 2006. IMTC 2006. Proceedings of the IEEE*, pages 43–48. IEEE, 2006.
- [12] Manuel Gonzalez-Hidalgo, FA Guerrero-Pena, S Herold-Garcia, Antoni Jaume-i Capó, and PD Marrero-Fernandez. Red blood cell cluster separation from digital images for use in sickle cell disease. *IEEE journal of biomedical and health informatics*, 19(4):1514–1525, 2015.
- [13] Petros S Karvelis, Alexandros T Tzallas, Dimitrios I Fotiadis, and Ioannis Georgiou. A multichannel watershed-based segmentation method for multispectral chromosome classification. *IEEE transactions on medical imaging*, 27(5):697–708, 2008.
- [14] Humayun Irshad, Antoine Veillard, Ludovic Roux, and Daniel Racocanu. Methods for nuclei detection, segmentation, and classification in digital histopathology: a review-current status and future potential. *IEEE reviews in biomedical engineering*, 7(99):97–114, 2014.
- [15] Jagath C e outros Cheng, Jierong e Rajapakse. Segmentação de núcleos agrupados com marcadores de formas e função de marcação. *Transações IEEE em Engenharia Biomédica*, 56.
- [16] Chanh Jung and Changick Kim. Segmenting clustered nuclei using h-minima transform-based marker extraction and contour parameterization. *IEEE transactions on biomedical engineering*, 57(10):2600–2604, 2010.
- [17] Chanh Jung, Changick Kim, Seoung Wan Chae, and Sukjoong Oh. Unsupervised Segmentation of Overlapped Nuclei Using Bayesian Classification. *IEEE Transactions on Biomedical Engineering*, 57(12):2825–2832, dec 2010.
- [18] Philip B Morgan, Craig A Woods, Deborah Jones, Nathan Efron, Kah-Ooi Tan, Martha Yanneth Gonzalez, Alice Pesinova, Hans-Juergen Grein, Svend-Erik Runberg, Ioannis G Tranoudis, et al. International contact lens prescribing in 2006. *Contact lens spectrum*, 21(1):34–34, 2007.
- [19] Alexandru C. Telea. *Data Visualization*. A K Peters, Ltd., 2007.
- [20] Roberto A. Lotufo, Romaric Audigier, André V. Saúde, and Rubens C. Machado. Morphological Image Processing. In Qiang Wu, Fatima A. Merchant, and Kenneth R. Castleman, editors, *Microscope Image Processing*, chapter 8, pages 113–157. Academic Press, Burlington, 2008.
- [21] Yue Huang, Xuezhi Sun, and Guangshu Hu. An automatic integrated approach for stained neuron detection in studying neuron migration. *Microscopy research and technique*, 73(2):109–18, feb 2010.
- [22] Serge Beucher and Fernand Meyer. The morphological approach to segmentation: the watershed transformation. *Optical Engineering-New York-Marcel Dekker Incorporated*, 34:433–433, 1992.
- [23] Gang Lin, Umesh Adiga, Kathy Olson, John F Guzowski, Carol A Barnes, and Badrinath Roysam. A hybrid 3d watershed algorithm incorporating gradient cues and object models for automatic segmentation of nuclei in confocal image stacks. *Cytometry Part A*, 56(1):23–36, 2003.
- [24] Qiang Wu, Fatima A. Merchant, Kenneth R. Castleman, Roberto A. Lotufo, Romaric Audigier, André V. Saúde, and Rubens C. Machado. Morphological Image Processing. In *Microscope image processing*, pages 113–157. 2008.
- [25] Yue Huang, Xiaobo Zhou, Benchun Miao, Marta Lipinski, Yong Zhang, Fuhai Li, Alexei Degterev, Junying Yuan, Guangshu Hu, and Stephen TC Wong. A computational framework for studying neuron morphology from in vitro high content neuron-based screening. *Journal of neuroscience methods*, 190(2):299–309, 2010.
- [26] Norberto Malpica, Carlos Ortiz de Solórzano, Juan José Vaquero, Andrés Santos, Isabel Vallcorba, José Miguel Garcia-Sagredo, and Francisco del Pozo. Applying watershed algorithms to the segmentation of clustered nuclei. 1997.
- [27] PS Umesh Adiga and BB Chaudhuri. An efficient method based on watershed and rule-based merging for segmentation of 3-d histopathological images. *Pattern Recognition*, 34(7):1449–1458, 2001.
- [28] Ricardo Fabbri, Luciano Da F Costa, Julio C Torelli, and Odemir M Bruno. 2d euclidean distance transform algorithms: A comparative survey. *ACM Computing Surveys (CSUR)*, 40(1):2, 2008.